

La Cocina de Kojo

Simulación de Eventos Discretos

Informe del Proyecto

Asignatura: Simulación

Problema No. 1: La Cocina de Kojo (Kojo's Kitchen)

Facultad de Matemática y Computación
Universidad de La Habana

Alumna: Alina María de la Noval Armenteros

Grupo: C-311

<https://github.com/alina-cyber04/kojo-kitchen-des>

8 de mayo de 2026

Índice

1. Introducción	1
1.1. Descripción del problema	1
1.2. Objetivos	2
1.3. Variables del sistema	2
2. Detalles de Implementación	3
2.1. Generador de números aleatorios (LCG)	3
2.2. Método de la transformada inversa	3
2.3. Streams independientes y Common Random Numbers (CRN)	4
2.4. Tipos de eventos	4
2.5. Algoritmo del bucle DES	5
2.6. Proceso de Poisson no homogéneo	6
2.7. Cálculo de la longitud media de cola	7
2.8. Protocolo de réplicas y parada	7
3. Resultados y Experimentos	8
3.1. Configuración experimental	8
3.2. Tabla de resultados	8
3.3. Comparación estadística entre escenarios	9
3.4. Análisis de parada de la simulación	10
3.5. Análisis de sensibilidad	12
3.6. Sensibilidad a la tasa de llegada fuera de hora pico	13
4. Modelo Matemático	15
4.1. Clasificación del sistema de colas	15
4.2. Parámetros del servicio	15
4.3. Utilización teórica y estabilidad	16
4.4. Aproximación M/M/c como cota teórica	16
4.5. Supuestos, restricciones y fuentes de discrepancia	17
5. Conclusiones	18
5.1. Recomendación principal	18
5.2. Hallazgos secundarios	18
5.3. Limitaciones del modelo	18
5.4. Posibles extensiones	19

1. Introducción

1.1. Descripción del problema

La Cocina de Kojo es un puesto de comida rápida ubicado en un centro comercial, con horario de atención de 10:00 am a 9:00 pm (660 minutos). El local ofrece dos tipos de productos: sándwiches y sushi. Para los objetivos de este estudio se asume que existen exclusivamente dos tipos de consumidores: los que consumen únicamente sándwiches y los que consumen únicamente productos de sushi.

El sistema experimenta dos períodos de hora pico durante la jornada laboral: el primero entre las 11:30 am y la 1:30 pm, y el segundo entre las 5:00 pm y las 7:00 pm. Fuera de estos períodos la demanda es notablemente menor. El intervalo de tiempo entre la llegada de un consumidor y el siguiente se modela como un proceso de Poisson homogéneo por tramos (no homogéneo globalmente), con distribución exponencial de parámetro λ :

- $\lambda_{\text{peak}} = 0,30$ clientes/min durante las horas pico,
- $\lambda_{\text{off-peak}} = 0,17$ clientes/min en el resto de la jornada.

Nota sobre los parámetros asumidos. El enunciado no especifica valores concretos para las tasas de llegada ni para la proporción de clientes por tipo de producto. Los valores $\lambda_{\text{peak}} = 0,30$ y $\lambda_{\text{off-peak}} = 0,17$ clientes/min se calibran a partir de referencias típicas de puestos de comida rápida en centros comerciales [1]: aproximadamente 18 clientes/hora en pico y 10 fuera de pico, con una razón $\lambda_{\text{peak}}/\lambda_{\text{off-peak}} \approx 1,76$. Análogamente, se asume $p = 0,5$ (igual proporción de clientes de sándwich y sushi) al no disponerse de datos históricos del local. El impacto de variaciones en λ_{peak} y $\lambda_{\text{off-peak}}$ se analiza en la section 3.5.

El tiempo de preparación de cada pedido depende del tipo de producto y sigue una distribución Uniforme:

- Sándwich: $S_{\text{sand}} \sim \mathcal{U}[3, 5]$ minutos,
- Sushi: $S_{\text{sush}} \sim \mathcal{U}[5, 8]$ minutos,

con probabilidad $p = 0,5$ de que cada cliente solicite sándwich.

Actualmente, dos empleados trabajan toda la jornada preparando pedidos. La administración ha recibido quejas de clientes por los tiempos de espera y desea evaluar si incorporar un tercer empleado durante las horas pico reduciría significativamente el problema.

1.2. Objetivos

El objetivo del estudio es comparar mediante simulación dos políticas de personal:

Escenario A (actual): 2 empleados activos durante toda la jornada.

Escenario B (alternativa): 2 empleados base más 1 empleado adicional exclusivamente durante las horas pico.

La **métrica principal de desempeño** es el porcentaje de clientes que esperan más de 5 minutos para recibir su pedido durante el transcurso de un día de trabajo. Métricas secundarias de interés son el tiempo de espera medio, la longitud media de la cola y la utilización de los empleados.

1.3. Variables del sistema

Table 1 resume las variables de entrada y de salida del modelo.

Cuadro 1: Variables del modelo de simulación.

Tipo	Variable	Distribución / Valor	Unidad
Entrada	Tasa de llegadas (pico)	$\lambda_{\text{peak}} = 0,30$	clientes/min
Entrada	Tasa de llegadas (fuera)	$\lambda_{\text{off-peak}} = 0,17$	clientes/min
Entrada	Servicio sándwich	$\mathcal{U}[3, 5]$	min
Entrada	Servicio sushi	$\mathcal{U}[5, 8]$	min
Entrada	Prob. cliente sándwich	$p = 0,5$	—
Entrada	Empleados base	$c = 2$	personas
Entrada	Empleados extra (Esc. B)	$e = 1$ en pico	personas
Salida	% clientes > 5 min	estimada por simulación	%
Salida	Tiempo de espera medio	estimado por simulación	min
Salida	Longitud media de la cola	estimada por simulación	clientes
Salida	Utilización de empleados	estimada por simulación	—

2. Detalles de Implementación

La simulación fue implementada íntegramente en Python 3.13, sin el uso de librerías de simulación externas (p.ej. SimPy), con el objetivo de exhibir explícitamente cada mecanismo del paradigma de eventos discretos. El código fuente se organiza en seis paquetes independientes: **rng** (generación aleatoria), **engine** (motor DES), **model** (dominio del restaurante), **metrics** (colección de estadísticos), **experiments** (ejecución de réplicas) y **analysis** (estadística y visualización).

2.1. Generador de números aleatorios (LCG)

La base del sistema estocástico es un **Generador Congruencial Lineal** (LCG), definido por la recurrencia [4]:

$$X_{n+1} = (A \cdot X_n + C) \text{ mód } M, \quad U_n = \frac{X_n}{M}, \quad (1)$$

con los parámetros popularizados por Press et al. en *Numerical Recipes* [7]:

$$A = 1\,664\,525, \quad C = 1\,013\,904\,223, \quad M = 2^{32}.$$

Estos parámetros satisfacen los criterios de Hull–Dobell [4] para período máximo igual a $M = 4\,294\,967\,296$, garantizando que la secuencia no se repite dentro de ninguna simulación práctica.

2.2. Método de la transformada inversa

Todas las variables aleatorias se generan mediante el método de la transformada inversa, cuya validez se sustenta en la siguiente proposición [2, 8].

Proposición (Transformada Inversa). Sea $U \sim \mathcal{U}(0, 1)$. Para cualquier función de distribución acumulada continua F , la variable aleatoria $X = F^{-1}(U)$ tiene distribución F .

Demostración. Sea $F_X(x) = P[X \leq x]$. Entonces:

$$F_X(x) = P[F^{-1}(U) \leq x] = P[U \leq F(x)] = F(x), \quad \square$$

donde la última igualdad es consecuencia de que U es uniforme en $(0, 1)$.

Distribución exponencial. Para modelar los tiempos entre llegadas se emplea $X \sim \text{Exp}(\lambda)$, con función de distribución $F(x) = 1 - e^{-\lambda x}$. Invertiendo:

$$X = -\frac{1}{\lambda} \ln(U). \quad (2)$$

Distribución uniforme. Los tiempos de preparación siguen $X \sim \mathcal{U}[a, b]$, con $F(x) = (x - a)/(b - a)$. La inversión da:

$$X = a + (b - a) U. \quad (3)$$

2.3. Streams independientes y Common Random Numbers (CRN)

Para garantizar comparaciones estadísticamente válidas entre escenarios se implementa la técnica de **números aleatorios comunes** (CRN) [5]. Se mantienen tres streams LCG independientes:

- **arrivals**: genera los tiempos entre llegadas sucesivas,
- **type**: determina si cada cliente pide sándwich o sushi,
- **service**: genera la duración de preparación de cada pedido.

Cada stream parte de una semilla separada por 10^6 posiciones:

$$\text{seed}_{\text{arrivals}} = s, \quad \text{seed}_{\text{type}} = s + 10^6, \quad \text{seed}_{\text{service}} = s + 2 \times 10^6.$$

Con ~ 200 clientes por día y 3 streams, el consumo máximo por réplica es de ≈ 600 números, muy inferior al gap de 10^6 .

El invariante clave del CRN es que el tiempo de servicio de cada cliente se sortea *en el momento de su llegada*, no cuando inicia el servicio. Así, el cliente k siempre consume el k -ésimo número del stream **service** independientemente del escenario. Esto induce correlación positiva $\rho > 0$ entre las réplicas pareadas de A y B, reduciendo la varianza del estimador de la diferencia:

$$\mathbb{V}(\bar{D}) = \mathbb{V}(\bar{A}) + \mathbb{V}(\bar{B}) - 2 \text{Cov}(A, B).$$

2.4. Tipos de eventos

El modelo define cinco tipos de eventos, descritos en table 2.

Cuadro 2: Tipos de eventos del modelo DES de La Cocina de Kojo.

Tipo	Descripción y acciones principales
ARRIVAL	Arribo de un nuevo cliente. Se determina su tipo (Bernoulli) y su tiempo de servicio (Uniforme, al llegar). Si hay servidor libre se asigna; si no, el cliente entra a la cola FIFO. Se programa la siguiente llegada.
DEPARTURE	Fin del servicio de un cliente. El servidor queda libre. Si la cola no está vacía se atiende al siguiente cliente. Si el empleado está marcado para retiro, se elimina.
PEAK_START	Comienzo de una hora pico. En el Escenario B se añade el empleado extra; si hay cola, comienza a atender de inmediato.
PEAK_END	Fin de una hora pico. En el Escenario B el empleado extra es marcado para retiro si está ocupado, o retirado inmediatamente si está libre.
END_OF_DAY	Cierre del día ($t = 660$ min). Los servicios en curso se completan; los clientes en cola no reciben servicio.

2.5. Algoritmo del bucle DES

El [algorithm 1](#) muestra el bucle principal de simulación, fiel al algoritmo de avance de tiempo por próximo evento descrito en Banks et al. [1].

Algoritmo 1 Bucle principal de la simulación DES**Entrada:** configuración `cfg`, streams `rng`**Salida:** `ReplicationResult` con métricas del día

```

1: Crear empleados base; programar primera ARRIVAL y eventos de pico
2: while la lista de eventos futuros (FEL) no está vacía do
3:    $e \leftarrow$  extraer evento de mínimo tiempo de la FEL
4:   Avanzar el reloj:  $t \leftarrow e.time$ 
5:   if  $e$  es ARRIVAL then
6:     Sortear tipo de cliente y  $s \leftarrow$  tiempo de servicio (Transformada Inversa)
7:     Crear cliente con arrival_time = t, service_time = s
8:     if existe servidor libre then
9:       Asignar cliente al servidor; programar DEPARTURE en  $t + s$ 
10:    else
11:      Encolar cliente; registrar cambio de cola
12:    end if
13:    Programar siguiente ARRIVAL en  $t + \text{Exp}(\lambda(t))$ 
14:  else if  $e$  es DEPARTURE then
15:    Liberar servidor; registrar departure_time = t
16:    if cola no vacía y  $t \leq T$  then
17:      Desencolar siguiente cliente; asignarlo; programar DEPARTURE
18:    end if
19:  else if  $e$  es PEAK_START y extra_staff > 0 then
20:    Crear empleado extra; si hay cola, asignarle cliente inmediatamente
21:  else if  $e$  es PEAK_END y extra_staff > 0 then
22:    Marcar empleado extra para retiro (o retirar si está libre)
23:  end if
24: end while
25: return MetricsCollector.summarize()

```

2.6. Proceso de Poisson no homogéneo

El proceso de llegadas es un proceso de Poisson no homogéneo con función de intensidad por tramos constantes [2]:

$$\lambda(t) = \begin{cases} 0,30 & \text{si } t \in [90, 210) \cup [420, 540), \\ 0,17 & \text{en otro caso.} \end{cases}$$

En la implementación, cada evento **ARRIVAL** programa el siguiente usando $\lambda(t_{\text{actual}})$: en cuanto el reloj supera una frontera de pico, la siguiente llegada ya utiliza la tasa correcta.

2.7. Cálculo de la longitud media de cola

La longitud media de cola se estima como el cociente entre el área bajo la curva $Q(t)$ (número de clientes en cola en el instante t) y la duración del día $T = 660$ min:

$$\bar{L}_q = \frac{1}{T} \int_0^T Q(t) dt \approx \frac{1}{T} \sum_k Q(t_k) (t_{k+1} - t_k), \quad (4)$$

donde la suma es una integral de Riemann por rectángulos actualizada en cada evento de cambio de cola. Este estimador es equivalente al que se obtiene aplicando la Ley de Little [6]: $L_q = \lambda W_q$.

2.8. Protocolo de réplicas y parada

Se ejecutan $n = 30$ réplicas independientes para cada escenario. La semilla de la réplica i es $s_i = 42 + i \times 10^5$, garantizando una separación mayor que el consumo por réplica (≈ 600 números). El criterio de parada formal propuesto en Colectivo de Simulación [3] (cap. 4) es:

$$\frac{S}{\sqrt{n}} < d, \quad (5)$$

donde d es la desviación estándar máxima admisible para el estimador. Este criterio se analiza en detalle en la section 3.4.

3. Resultados y Experimentos

3.1. Configuración experimental

Se ejecutaron 30 réplicas de cada escenario usando números aleatorios comunes (CRN) con semilla base $s_0 = 42$. Cada réplica modela un día completo de operación (660 minutos). La correlación observada entre las réplicas pareadas fue $\hat{\rho} = 0,552$, confirmando la eficacia del CRN.

3.2. Tabla de resultados

La table 3 presenta la media y el intervalo de confianza al 95 % (distribución t de Student con $n - 1 = 29$ grados de libertad) para cada métrica de salida.

Cuadro 3: Resultados de la simulación — media e IC 95 % (30 réplicas, CRN).

Métrica	Escenario A		Escenario B	
	Media	IC 95 %	Media	IC 95 %
% clientes > 5 min	16.70	[13.69, 19.72]	3.10	[2.01, 4.19]
Espera media (min)	2.185	[1.880, 2.491]	0.658	[0.566, 0.750]
Espera máxima (min)	13.46	[12.00, 14.93]	7.37	[6.51, 8.22]
Longitud media de cola (clientes)	0.482	[0.408, 0.556]	0.146	[0.123, 0.169]
Utilización media (%)	57.16	[55.67, 58.66]	50.16	[48.82, 51.50]

Los intervalos de confianza de ambos escenarios no se solapan en ninguna métrica, lo cual sugiere diferencias sustanciales; la significancia se verifica formalmente con el test pareado que se reporta a continuación.

La fig. 1 presenta una visión integrada de los cuatro indicadores principales.




Figura 1: Panel comparativo con las cuatro métricas principales. Barras de error = IC 95 %; notches en box plots = IC 95 % de la mediana (bootstrap, $B = 5000$).

3.3. Comparación estadística entre escenarios

Se emplea un ***t*-test pareado** (también llamado test de muestras relacionadas), ya que las réplicas de A y B están emparejadas por CRN. El test trabaja sobre las diferencias $D_i = A_i - B_i$:

$$H_0 : \mu_D = 0 \quad \text{vs.} \quad H_1 : \mu_D \neq 0,$$

con estadístico $t = \bar{D} / (S_D / \sqrt{n})$. Los resultados son:

Diferencia media $\bar{D}$	13,61 %
IC 95 % de $\bar{D}$	[11,03, 16,18] %
Estadístico t	10,799
p -value	$1,12 \times 10^{-11}$
Significativo ($\alpha = 0,05$)	Sí

El intervalo de confianza de la diferencia no contiene el cero. Se rechaza H_0 con un nivel de confianza superior al 99,99 %: el tercer empleado reduce significativamente el porcentaje de clientes insatisfechos.

La fig. 2 muestra la distribución de los tiempos de espera a través de las 30 réplicas. Los notches (IC 95 % de la mediana) de ambos escenarios no se solapan, corroborando el test paramétrico con una técnica no paramétrica.




Figura 2: Box plots del tiempo de espera medio por réplica. Los notches representan el IC 95 % de la mediana (bootstrap, $B = 5\,000$).

3.4. Análisis de parada de la simulación

El criterio de parada de Colectivo de Simulación [3] establece continuar hasta que $S/\sqrt{n} < d$. Equivalentemente, el número mínimo de réplicas para una precisión relativa r es [5]:

$$n^* = \left\lceil \left(\frac{t_{\alpha/2, n-1} \hat{S}}{r \bar{x}} \right)^2 \right\rceil, \quad (6)$$

con $r = 0,05$ (5 % de precisión relativa).

Los resultados de aplicar la eq. (6) son:

Escenario	$\bar{x}$ (%)	$\hat{S}$ (%)	n^* (5 % relativo)	Semi-anchura (%)
A	16,70	8,07	391	3,01
B	3,10	2,93	1493	1,09

Interpretación. El criterio de precisión relativa del 5 % no se satisface con 30 réplicas. Esto se debe a la alta variabilidad intrínseca del indicador: el coeficiente de variación es $CV_A = 8,07/16,70 \approx 48$ % para el Escenario A y $CV_B = 2,93/3,10 \approx 94$ % para el Escenario B. Un CV tan elevado en el Escenario B es consecuencia de que el

porcentaje de clientes insatisfechos es pequeño (media del 3,1 %) pero con alta dispersión entre réplicas: algunos días no se produce ninguna espera larga, mientras que otros sí. En estas condiciones, alcanzar una precisión relativa del 5 % requeriría del orden de 400–1500 réplicas.

Precisión absoluta. Una forma alternativa de evaluar la suficiencia de las réplicas es mediante la semi-anchura del IC en términos absolutos. Con 30 réplicas se obtiene:

- Escenario A: IC 95 % = [13,69; 19,72] %, semi-anchura = 3,01 %.
- Escenario B: IC 95 % = [2,01; 4,19] %, semi-anchura = 1,09 %.

Para la decisión de política de personal, conocer que el Escenario A produce entre el 13,7 % y el 19,7 % de clientes insatisfechos, frente al 2,0 %–4,2 % del Escenario B, es más que suficiente. La diferencia entre ambos intervalos es de varios órdenes de magnitud y no depende de la estimación puntual exacta.

Suficiencia para la hipótesis principal. Aunque la precisión relativa del 5 % no se alcanza, el p -value de $1,12 \times 10^{-11}$ demuestra que la diferencia entre escenarios es estadísticamente detectable con garantía absoluta usando 30 réplicas. El criterio de Colectivo de Simulación [3] controla la precisión de la *estimación puntual*; la *detección de diferencias* (objetivo principal del estudio) requiere potencia estadística, no precisión de estimación, y esa potencia queda demostrada. Por tanto, 30 réplicas son suficientes para responder la pregunta de negocio, aunque se recomendaría aumentarlas si el objetivo fuera reportar el porcentaje exacto del Escenario B con mayor certeza.

La fig. 3 muestra cómo la media acumulada de cada escenario se estabiliza alrededor de las réplicas 15–20, confirmando que el estimador converge dentro del experimento de 30 réplicas.




Figura 3: Convergencia del estimador $\bar{x}_k$ (media acumulada tras k réplicas). La línea discontinua indica la estimación final.




Figura 4: Resultados individuales de las 30 réplicas para cada escenario. La línea gruesa es la media; la banda sombreada es el IC 95 %.

3.5. Análisis de sensibilidad

El enunciado requiere analizar el impacto de la variación de los parámetros del problema. Se estudia la sensibilidad de la métrica principal al parámetro más influyente: la **tasa de llegadas en hora pico** λ_{peak} .

Se ejecutan 10 réplicas por punto para valores $\lambda_{\text{peak}} \in \{0,10, 0,15, \dots, 0,50\}$, manteniendo constantes el resto de parámetros.




Figura 5: Sensibilidad del % de clientes con espera > 5 min ante variaciones en λ_{peak} . La banda sombreada es el IC 95 %. La línea discontinua gris marca el valor nominal del problema ($\lambda = 0,30$).

La fig. 5 revela varias conclusiones importantes:

- Para $\lambda_{\text{peak}} \leq 0,20$ clientes/min ambos escenarios presentan porcentajes de insatisfacción inferiores al 5 %; la inversión en personal extra no está justificada a esas tasas.
- En el valor nominal $\lambda = 0,30$, el Escenario B reduce el indicador de 16,7 % a 3,1 %.
- A partir de $\lambda_{\text{peak}} \approx 0,42$ el Escenario B también comienza a saturarse (supera el 10 %), indicando que para tasas más altas sería necesario incorporar un cuarto empleado durante las horas pico.

3.6. Sensibilidad a la tasa de llegada fuera de hora pico

Se analiza también el impacto de variaciones en la tasa de llegadas fuera de las horas pico $\lambda_{\text{off-peak}}$. Se ejecutan 10 réplicas por punto; los valores evaluados son $\lambda_{\text{off-peak}} \in \{0,05; 0,10; \dots; 0,35\}$, manteniendo $\lambda_{\text{peak}} = 0,30$ y el resto de parámetros fijos.




Figura 6: Sensibilidad del % de clientes con espera > 5 min ante variaciones en $\lambda_{\text{off-peak}}$. La banda sombreada es el IC 95 %. La línea discontinua gris marca el valor nominal ($\lambda_{\text{off-peak}} = 0,17$).

La fig. 6 muestra que:

- La tasa fuera de pico tiene un impacto moderado en comparación con λ_{peak} : incluso duplicando $\lambda_{\text{off-peak}}$ desde 0,17 hasta 0,34, el incremento en el porcentaje de insatisfacción es notablemente menor que el producido por variaciones equivalentes en la tasa de pico.
- El Escenario B mantiene su ventaja frente a A en todo el rango analizado, lo que confirma que la recomendación de incorporar un tercer empleado en horas pico es robusta ante fluctuaciones en la demanda fuera de pico.
- Para $\lambda_{\text{off-peak}} \gtrsim 0,30$ clientes/min (valor comparable a la tasa de pico), el sistema comienza a saturarse incluso fuera de las horas pico, por lo que en ese régimen sería necesario revisar la dotación base de empleados.

4. Modelo Matemático

4.1. Clasificación del sistema de colas

El sistema de La Cocina de Kojo puede clasificarse, usando la notación de Kendall, como un sistema $M/G/c$:

- **M** (Markoviano): las llegadas de clientes forman un proceso de Poisson, cuyos tiempos entre eventos son variables exponenciales independientes — memoria nula entre llegadas sucesivas.
- **G** (General): los tiempos de servicio siguen distribuciones uniformes, no exponenciales.
- **c**: hay $c \in \{2, 3\}$ servidores paralelos con cola única FIFO.

Dado que la tasa de llegadas no es constante a lo largo del día, el modelo global es en realidad un sistema $M/G/c$ *no estacionario*. El análisis teórico que sigue trata cada período (pico / fuera de pico) de forma independiente asumiendo condiciones de régimen estacionario dentro de cada tramo.

4.2. Parámetros del servicio

Tiempo de servicio esperado. Con probabilidad $p = 0,5$ el cliente pide sándwich ($S_{\text{sand}} \sim \mathcal{U}[3, 5]$) y con probabilidad $1 - p = 0,5$ pide sushi ($S_{\text{sush}} \sim \mathcal{U}[5, 8]$). La esperanza del tiempo de servicio es:

$$\begin{aligned}\mathbb{E}[S] &= p \mathbb{E}[S_{\text{sand}}] + (1 - p) \mathbb{E}[S_{\text{sush}}] \\ &= 0,5 \cdot \frac{3+5}{2} + 0,5 \cdot \frac{5+8}{2} = 0,5 \times 4 + 0,5 \times 6,5 = \mathbf{5,25} \text{ min.}\end{aligned}\tag{7}$$

La tasa de servicio de un empleado es:

$$\mu = \frac{1}{\mathbb{E}[S]} = \frac{1}{5,25} \approx 0,1905 \text{ clientes/min.}$$

Segundo momento y varianza del servicio. Para $X \sim \mathcal{U}[a, b]$ se tiene $\mathbb{E}[X^2] = (a^2 + ab + b^2)/3$. Por tanto:

$$\mathbb{E}[S_{\text{sand}}^2] = \frac{9 + 15 + 25}{3} = \frac{49}{3} \approx 16,33, \quad \mathbb{E}[S_{\text{sush}}^2] = \frac{25 + 40 + 64}{3} = 43.$$

$$\mathbb{E}[S^2] = 0,5 \times \frac{49}{3} + 0,5 \times 43 = 8,167 + 21,5 = \mathbf{29,67} \text{ min}^2.$$

$$\mathbb{V}[S] = \mathbb{E}[S^2] - (\mathbb{E}[S])^2 = 29,67 - 5,25^2 = 29,67 - 27,5625 \approx \mathbf{2,11} \text{ min}^2, \quad \sigma_S \approx 1,45 \text{ min.}$$

4.3. Utilización teórica y estabilidad

La **utilización** de cada servidor en el período analizado es:

$$\rho = \frac{\lambda}{c \cdot \mu}, \quad (8)$$

con la condición de estabilidad $\rho < 1$. La table 4 muestra los valores para cada combinación de período y escenario.

Cuadro 4: Utilización teórica ρ por período y escenario.

Período	Escenario	λ	c	μ	$\rho = \lambda/(c\mu)$
Fuera de pico	A	0,17	2	0,1905	0,446
Fuera de pico	B	0,17	2	0,1905	0,446
Pico	A	0,30	2	0,1905	0,787
Pico	B	0,30	3	0,1905	0,525

En todos los casos $\rho < 1$: el sistema es estable en cada período. La carga más exigente corresponde al período pico del Escenario A ($\rho = 0,787$), lo que explica la acumulación de cola observada en la simulación.

4.4. Aproximación M/M/c como cota teórica

Para obtener predicciones analíticas se aproxima el sistema M/G/c por un sistema M/M/c con la misma tasa media de servicio. Aunque los tiempos de servicio no son exponenciales, este modelo proporciona una cota de referencia útil.

Fórmula de Erlang C. La probabilidad de que un cliente deba esperar en cola es [1]:

$$C(c, a) = \frac{\frac{a^c}{c!} \cdot \frac{c}{c-a}}{\sum_{n=0}^{c-1} \frac{a^n}{n!} + \frac{a^c}{c!} \cdot \frac{c}{c-a}}, \quad (9)$$

donde $a = \lambda/\mu$ es la intensidad de tráfico.

Tiempo de espera en cola (M/M/c).

$$W_q^{\text{MMc}} = \frac{C(c, a)}{c \mu (1 - \rho)}. \quad (10)$$

Longitud media de cola. Por la Ley de Little [6]:

$$L_q = \lambda W_q. \quad (11)$$

Los resultados se muestran en la table 5. Los valores teóricos se calculan como media ponderada por tiempo de los dos períodos del día: $W_q^{\text{día}} = \frac{240}{660} W_q^{\text{peak}} + \frac{420}{660} W_q^{\text{off-peak}}$, con $\lambda_{\text{eff}} = \frac{240 \times 0,30 + 420 \times 0,17}{660} = 0,217$ clientes/min.

Cuadro 5: Comparación teoría M/M/c vs. simulación — media ponderada del día completo.

Escenario	Indicador	M/M/c teórico	Sim. (media)	Sim – Teo (%)
A ($c_{\text{peak}} = 2$)	W_q (min)	3,95	2,19	−44,6
A ($c_{\text{peak}} = 2$)	L_q (clientes)	0,86	0,48	−44,2
B ($c_{\text{peak}} = 3$)	W_q (min)	1,18	0,66	−44,1
B ($c_{\text{peak}} = 3$)	L_q (clientes)	0,26	0,15	−42,3

4.5. Supuestos, restricciones y fuentes de discrepancia

Las diferencias entre el modelo M/M/c y la simulación se explican por varios factores:

1. **Distribución del servicio (factor dominante).** Los tiempos de servicio son uniformes, no exponenciales. La distribución exponencial tiene coeficiente de variación $C_v = 1$, mientras que $\mathcal{U}[3, 5]$ tiene $C_v = 0,14$, $\mathcal{U}[5, 8]$ tiene $C_v = 0,13$, y la mezcla combinada tiene $C_v = \sigma_S / \mathbb{E}[S] = 1,45/5,25 \approx 0,28$. Tiempos de servicio mucho menos variables que los exponenciales generan colas notablemente menores, como predice la fórmula de Pollaczek–Khinchine [8]. Este factor explica que la simulación dé resultados aprox. 44 % menores que M/M/c de manera consistente en ambos escenarios.
2. **No estacionariedad.** La tasa $\lambda(t)$ cambia a lo largo del día. El modelo estacionario sobreestima el efecto del pico porque asume que la tasa alta ha estado vigente indefinidamente, acumulando más cola de la real.
3. **Condición transitoria.** Al inicio de cada período pico el sistema parte de una cola residual, no del estado de régimen estacionario que asume el modelo analítico.
4. **Jornada finita.** La Ley de Little y la fórmula de Erlang C son resultados de largo plazo (régimen estacionario); aquí el horizonte es de 660 min.

Verificación con la Ley de Little. Se puede verificar internamente la consistencia de la simulación usando $L_q = \lambda_{\text{eff}} W_q$, donde λ_{eff} es la tasa efectiva de clientes atendidos. Para el Escenario A: $0,482 \approx (144,2/660) \times 2,185 = 0,218 \times 2,185 = 0,477 \checkmark$

5. Conclusiones

5.1. Recomendación principal

La simulación de 30 réplicas por escenario, emparejadas mediante números aleatorios comunes, proporciona evidencia estadística abrumadora ($p = 1,12 \times 10^{-11}$, $t = 10,8$, IC de la diferencia [11,03; 16,18] %) de que incorporar un tercer empleado durante las horas pico reduce el porcentaje de clientes con espera superior a 5 minutos de **16,7 %** (Escenario A) a **3,1 %** (Escenario B), una mejora del 81,4 %.

Se **recomienda adoptar el Escenario B** para la tasa de llegadas actual ($\lambda_{\text{peak}} = 0,30$ clientes/min).

5.2. Hallazgos secundarios

- El tiempo de espera medio se reduce de 2,19 min a 0,66 min.
- La longitud media de la cola decrece de 0,48 a 0,15 clientes.
- La utilización del personal baja del 57,2 % al 50,2 %, manteniéndose en niveles saludables que permiten absorber picos transitorios sin colapsar el sistema.
- El análisis de sensibilidad revela que la ventaja del Escenario B se mantiene para $\lambda_{\text{peak}} \lesssim 0,42$; por encima de ese umbral sería necesario incorporar un cuarto empleado.

5.3. Limitaciones del modelo

1. **Disciplina de cola:** se asume FIFO estricto; no se modela abandono (reneging) ni impaciencia de los clientes.
2. **Homogeneidad de empleados:** todos los servidores tienen la misma distribución de servicio; no se considera variabilidad inter-empleado.
3. **Jornada determinista:** el horario de apertura y cierre, y las fronteras de hora pico, son fijas. En la práctica pueden fluctuar.
4. **Sin descansos ni ausencias:** el modelo asume disponibilidad continua de los empleados.
5. **Modelo no estacionario aproximado:** la generación de llegadas usa tasas constantes por tramos, no un proceso de Poisson no homogéneo exacto.

5.4. Posibles extensiones

- Incorporar abandono de cola: modelar que los clientes se van si la espera estimada supera un umbral.
- Optimizar el número óptimo de empleados extra como función de λ_{peak} , generalizando el análisis de sensibilidad.
- Ajustar las distribuciones de servicio a datos reales del local (análisis de bondad de ajuste).
- Extender el análisis de parada usando métodos secuenciales (semi-anchura fija) para garantizar el criterio del 5 % de precisión relativa [5].

Referencias

- [1] Jerry Banks, John S. Carson, Barry L. Nelson, and David M. Nicol. *Discrete-Event System Simulation*. Prentice Hall, Upper Saddle River, NJ, 5 edition, 2010.
- [2] Colectivo de Simulación. Generación de variables aleatorias, 2024. Materiales del curso, Universidad de La Habana.
- [3] Colectivo de Simulación. Temas de simulación, 2024. Materiales del curso, Universidad de La Habana.
- [4] Donald E. Knuth. *The Art of Computer Programming, Vol. 2: Seminumerical Algorithms*. Addison-Wesley, Reading, MA, 3 edition, 1997.
- [5] Averill M. Law. *Simulation Modeling and Analysis*. McGraw-Hill, New York, 5 edition, 2015.
- [6] John D.C. Little. A proof for the queuing formula: $l = \lambda w$. *Operations Research*, 9 (3):383–387, 1961.
- [7] William H. Press, Saul A. Teukolsky, William T. Vetterling, and Brian P. Flannery. *Numerical Recipes: The Art of Scientific Computing*. Cambridge University Press, Cambridge, 3 edition, 2007.
- [8] Sheldon M. Ross. *Simulation*. Academic Press, Waltham, MA, 5 edition, 2013.